

知乎

```


$$r_0 = \mathbf{D}^{(0)} \mathbf{q}_0$$

for  $i = 0, \dots, L - 1$ 
{
     $j = i + \delta$  ;
     $\beta_j = \rho_j \mathbf{y}_j^T \mathbf{r}_i$  ;
     $\mathbf{r}_{i+1} = \mathbf{r}_i + (\alpha_i - \beta_i) \mathbf{s}_j$  ;
}

```

牛顿法



大咸鱼

9 人赞同了该文章

牛顿法被称为牛顿-拉夫逊（Newton-Raphson）方法。牛顿在17世纪提出用来求解方程的根。

假设点 x^* 为函数 $f(x)$ 的根，则 $f(x^*)=0$ 。

将函数 $f(x)$ 在点

$$x^{(t)}$$

处进行一阶泰勒展开有：

$$f(x) \approx f(x^{(t)}) + (x - x^{(t)})f'(x^{(t)})$$

假设点

$$x^{(t+1)}$$

为函数 $f(x)$ 的根，则有：

那么可以得到：

$$x^{(t+1)} = x^{(t)} - \frac{f(x^{(t)})}{f'(x^{(t)})}$$

牛顿法通过迭代的方式求解方程f(x)=0的解。

牛顿法求解目标函数极值

对于最优化问题，极值点处函数的一阶导数为0

可以对一阶导数

$$g(x) = f'(x)$$

利用牛顿法通过迭代的方式来求得最优解，即相当于求一阶导数对应函数的根。

$$x^{(t+1)} = x^{(t)} - \frac{f(x^{(t)})}{f'(x^{(t)})} \xrightarrow{g(x) = f'(x)} x^{(t+1)} = x^{(t)} - \frac{g(x^{(t)})}{g'(x^{(t)})} = x^{(t)} - \frac{f'(x^{(t)})}{f''(x^{(t)})}$$

牛顿法是二阶最优化算法。

对多元函数

$$f(x_1, \dots, x_D)$$

，一阶导数换成梯度：

$$\nabla f(x_1, \dots, x_D)$$

，二阶导数换成海森（Hessian）矩阵H，

$$\mathbf{H}(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_D} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_D} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_1 \partial x_D} & \frac{\partial^2 f}{\partial x_D \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_D^2} \end{bmatrix}$$



知乎

切换

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - \mathbf{H}^{-1}(\mathbf{x}^{(t)}) \nabla f(\mathbf{x}^{(t)})$$

牛顿法求解目标函数极值步骤：

1、从t=0开始，初始化

$$\mathbf{x}^{(0)}$$

为随机值；

2、计算目标函数f(x)在点

$$\mathbf{x}^{(t)}$$

的梯度

$$\mathbf{g}^{(t)} = \nabla f(\mathbf{x}^{(t)})$$

和海森矩阵

$$\mathbf{H}^{(t)} = \mathbf{H}(\mathbf{x}^{(t)})$$

3、计算移动方向：

$$\mathbf{d}^{(t)} = (\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}$$

(一般用线性方程组计算

$$\mathbf{d}^{(t)} : \mathbf{H}^{(t)} \mathbf{d}^{(t)} = -\mathbf{g}^{(t)}$$

。线性方程组求解可用共轭梯度等方法求解)。

4、根据迭代公式，更新x的值：

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} + \mathbf{d}^{(t)}$$

$$\mathbf{x}^{(t+1)}$$

和目标函数最小值

$$f(\mathbf{x}^{(t+1)})$$

否则转到第2步。

与一阶梯度法

$$\mathbf{d}^{(t)} = -\eta \mathbf{g}^{(t)}$$

移动方向为：

$$\mathbf{d}^{(t)} = -(\mathbf{H}^{(t)})^{-1} \mathbf{g}^{(t)}$$

拟牛顿法

牛顿法比一般的梯度下降法收敛速度快。

但在高维情况下，计算目标函数的二阶偏导数的复杂度大，而且有时候目标函数的海森矩阵无法保持正定，不存在逆矩阵，此时牛顿法将不再能使用

因此，人们提出了拟牛顿法（Quasi-Newton Methods）：不用二阶偏导数构造出可以近似 Hessian 矩阵（或 Hessian 矩阵的逆矩阵）的正定对称矩阵，进而再逐步优化目标函数。

不同的 Hessian 矩阵构造方法产生了不同的拟牛顿法：

BFGS/L-BFGS

拟牛顿条件

在t次迭代后，得到

$$\mathbf{x}^{(t+1)}$$

将目标函数f(x)在

$$\mathbf{x}^{(t+1)}$$

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(t+1)}) + (\mathbf{x} - \mathbf{x}^{(t+1)})^T \nabla f(\mathbf{x}^{(t+1)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(t+1)})^T \nabla^2 f(\mathbf{x}^{(t+1)}) (\mathbf{x} - \mathbf{x}^{(t+1)})$$

两边同时取梯度运算 ∇ ，得到

$$\nabla f(\mathbf{x}) \approx \nabla f(\mathbf{x}^{(t+1)}) + \nabla^2 f(\mathbf{x}^{(t+1)}) (\mathbf{x} - \mathbf{x}^{(t+1)})$$

取

$$\mathbf{x} = \mathbf{x}^{(t)}$$

，令

$$\mathbf{g}^{(t)} = \nabla f(\mathbf{x}^{(t)})$$

，

$$\mathbf{H}^{(t)} = \nabla^2 f(\mathbf{x}^{(t)})$$

，则

$$\mathbf{g}^{(t+1)} - \mathbf{g}^{(t)} \approx \mathbf{H}^{(t+1)} (\mathbf{x}^{(t+1)} - \mathbf{x}^{(t)})$$

引入记号

$$\mathbf{s}^{(t)} = \mathbf{x}^{(t+1)} - \mathbf{x}^{(t)}$$

，

$$\mathbf{y}^{(t)} = \mathbf{g}^{(t+1)} - \mathbf{g}^{(t)}$$

，则

$$\mathbf{y}^{(t)} \approx \mathbf{H}^{(t+1)} \mathbf{s}^{(t)}$$

令B表示H的近似，D表示

$$\mathbf{H}^{-1}$$

的近似，根据

$$\mathbf{y}^{(t)} \approx \mathbf{H}^{(t+1)} \mathbf{s}^{(t)}$$

得到拟牛顿条件为：

$$\mathbf{y}^{(t)} = \mathbf{B}^{(t+1)} \mathbf{s}^{(t)}$$

或：

$$\mathbf{s}^{(t)} = \mathbf{D}^{(t+1)} \mathbf{y}^{(t)}$$

BFGS

BFGS算法是Broyden,Fletcher,Goldfarb,Shanno四位研究者发明出来的，被认为是数值效果最好的拟牛顿法，并且具有全局收敛性和超线性收敛速度。

BFGS算法使用迭代法逼近Hessian矩阵：

$$\mathbf{B}^{(t+1)} = \mathbf{B}^{(t)} + \Delta \mathbf{B}^{(t)}$$

初始值

$$\mathbf{B}^{(0)} = \mathbf{I}$$

为单位矩阵，因此关键是如何构造

$$\Delta \mathbf{B}^{(t)}$$

为了保证矩阵B的正定性，令

$$\Delta \mathbf{B}^{(t)} = \alpha \mathbf{u} \mathbf{u}^T + \beta \mathbf{v} \mathbf{v}^T$$

，代入

$$\mathbf{f}^{(t+1)} = \mathbf{f}^{(t)} + \mathbf{B}^{(t+1)} \mathbf{s}^{(t)}$$

知乎

切换

$$\begin{aligned}
 &= \mathbf{B}^{(t)} \mathbf{s}^{(t)} + \alpha \mathbf{u} \mathbf{u}^T \mathbf{s}^{(t)} + \beta \mathbf{v} \mathbf{v}^T \mathbf{s}^{(t)} \\
 &= \mathbf{B}^{(t)} \mathbf{s}^{(t)} + \mathbf{u}(\alpha \mathbf{u}^T \mathbf{s}^{(t)}) + \mathbf{v}(\beta \mathbf{v}^T \mathbf{s}^{(t)})
 \end{aligned}$$

$$\mathbf{y}^{(t)} = \mathbf{B}^{(t)} \mathbf{s}^{(t)} + \mathbf{u}(\alpha \mathbf{u}^T \mathbf{s}^{(t)}) + \mathbf{v}(\beta \mathbf{v}^T \mathbf{s}^{(t)})$$

令

$$\alpha \mathbf{u}^T \mathbf{s}^{(t)} = 1, \quad \beta \mathbf{v}^T \mathbf{s}^{(t)} = -1$$

, 得到:

$$\alpha = \frac{1}{\mathbf{u}^T \mathbf{s}^{(t)}}, \quad \beta = -\frac{1}{\mathbf{v}^T \mathbf{s}^{(t)}}$$

将

$$\alpha \mathbf{u}^T \mathbf{s}^{(t)} = 1, \quad \beta \mathbf{v}^T \mathbf{s}^{(t)} = -1$$

代入

$$\mathbf{y}^{(t)} = \mathbf{B}^{(t)} \mathbf{s}^{(t)} + \mathbf{u}(\alpha \mathbf{u}^T \mathbf{s}^{(t)}) + \mathbf{v}(\beta \mathbf{v}^T \mathbf{s}^{(t)}) = \mathbf{B}^{(t)} \mathbf{s}^{(t)} + \mathbf{u} - \mathbf{v}$$

得到:

$$\mathbf{u} - \mathbf{v} = \mathbf{y}^{(t)} - \mathbf{B}^{(t)} \mathbf{s}^{(t)}$$

不妨令

$$\mathbf{u} = \mathbf{y}^{(t)}, \quad \mathbf{v} = \mathbf{B}^{(t)} \mathbf{s}^{(t)}$$

, 代入

$$\begin{aligned}
 \alpha &= \frac{1}{\mathbf{u}^T \mathbf{s}^{(t)}} = \frac{1}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}}, \\
 \beta &= -\frac{1}{\mathbf{v}^T \mathbf{s}^{(t)}} = -\frac{1}{(\mathbf{B}^{(t)} \mathbf{s}^{(t)})^T \mathbf{s}^{(t)}} = -\frac{1}{(\mathbf{s}^{(t)})^T (\mathbf{B}^{(t)})^T \mathbf{s}^{(t)}}
 \end{aligned}$$

$$= \frac{\mathbf{y}^{(t)}(\mathbf{y}^{(t)})^T}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}} - \frac{\mathbf{B}^{(t)} \mathbf{s}^{(t)} (\mathbf{B}^{(t)} \mathbf{s}^{(t)})^T}{(\mathbf{s}^{(t)})^T (\mathbf{B}^{(t)})^T \mathbf{s}^{(t)}}$$

牛顿法中需要计算Hessian矩阵的逆矩阵。

根据Sherman-Morrison公式，可得到

$$(\mathbf{B}^{(t+1)})^{-1} = \mathbf{D}^{(t+1)} = \left(\mathbf{I} - \frac{\mathbf{s}^{(t)}(\mathbf{y}^{(t)})^T}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}} \right) \mathbf{D}^{(t)} \left(\mathbf{I} - \frac{\mathbf{y}^{(t)}(\mathbf{s}^{(t)})^T}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}} \right) + \frac{\mathbf{s}^{(t)}(\mathbf{s}^{(t)})^T}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}}$$

Sherman-Morrison公式：若A为非奇异方阵，

$$1 + \mathbf{v}^T \mathbf{A}^{-1} \mathbf{u} \neq 0$$

，则

$$(\mathbf{A} + \mathbf{u}\mathbf{v}^T)^{-1} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1} \mathbf{u} \mathbf{v}^T \mathbf{A}^{-1}}{1 + \mathbf{v}^T \mathbf{A}^{-1} \mathbf{u}}$$

BFGS更新参数的流程：

1、从t=0开始，初始化

$$\mathbf{D}^{(0)} = \mathbf{I}$$

2、计算移动方向：

$$\mathbf{d}^{(t)} = \mathbf{D}^{(t)} \mathbf{g}^{(t)}$$

3、更新x的值：

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - \mathbf{d}^{(t)}$$

4、

$$\mathbf{s}^{(t)} = \mathbf{d}^{(t)}$$

5、若

, 迭代终止;

6、计算:

$$\mathbf{y}^{(t)} = \mathbf{g}^{(t+1)} - \mathbf{g}^{(t)}$$

7、 $t=t+1$, 转第2步。

L-BFGS

L-BFGS (limited memory BFGS) 不直接存储Hessian矩阵, 而是通过存储计算过程中产生的

$$\mathbf{s}^{(t)}$$

和

$$\mathbf{y}^{(t)}$$

来计算Hessian矩阵, 从而减少参数存储所需空间。

BFGS中Hessian矩阵更新公式为:

$$\mathbf{D}^{(t+1)} = \left(\mathbf{I} - \frac{\mathbf{s}^{(t)}(\mathbf{y}^{(t)})^T}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}} \right) \mathbf{D}^{(t)} \left(\mathbf{I} - \frac{\mathbf{y}^{(t)}(\mathbf{s}^{(t)})^T}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}} \right) + \frac{\mathbf{s}^{(t)}(\mathbf{s}^{(t)})^T}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}}$$

令

$$\rho^{(t)} = \frac{1}{(\mathbf{y}^{(t)})^T \mathbf{s}^{(t)}}$$

知乎

切换

则：

$$\mathbf{D}^{(t+1)} = (\mathbf{V}^{(t)})^T \mathbf{D}^{(t)} \mathbf{V}^{(t)} + \rho^{(t)} \mathbf{s}^{(t)} (\mathbf{s}^{(t)})^T$$

展开：

$$\mathbf{D}^{(1)} = (\mathbf{V}^{(0)})^T \mathbf{D}^{(0)} \mathbf{V}^{(0)} + \rho^{(0)} \mathbf{s}^{(0)} (\mathbf{s}^{(0)})^T$$

$$\begin{aligned} \mathbf{D}^{(2)} &= (\mathbf{V}^{(1)})^T \mathbf{D}^{(1)} \mathbf{V}^{(1)} + \rho^{(1)} \mathbf{s}^{(1)} (\mathbf{s}^{(1)})^T \\ &= (\mathbf{V}^{(1)})^T \left((\mathbf{V}^{(0)})^T \mathbf{D}^{(0)} \mathbf{V}^{(0)} + \rho^{(0)} \mathbf{s}^{(0)} (\mathbf{s}^{(0)})^T \right) \mathbf{V}^{(1)} + \rho^{(1)} \mathbf{s}^{(1)} (\mathbf{s}^{(1)})^T \\ &= (\mathbf{V}^{(1)})^T (\mathbf{V}^{(0)})^T \mathbf{D}^{(0)} \mathbf{V}^{(0)} \mathbf{V}^{(1)} + (\mathbf{V}^{(1)})^T \rho^{(0)} \mathbf{s}^{(0)} (\mathbf{s}^{(0)})^T \mathbf{V}^{(1)} + \rho^{(1)} \mathbf{s}^{(1)} (\mathbf{s}^{(1)})^T \end{aligned}$$

一般地：

$$\begin{aligned} \mathbf{D}^{(t+1)} &= (\mathbf{V}^{(t)})^t (\mathbf{V}^{(t-1)})^t \dots (\mathbf{V}^{(0)})^t \mathbf{D}^{(0)} \mathbf{V}^{(0)} \mathbf{V}^{(1)} \dots \mathbf{V}^{(t)} \\ &\quad + (\mathbf{V}^{(t)})^T (\mathbf{V}^{(t-1)})^T \dots (\mathbf{V}^{(1)})^T \rho^{(0)} \mathbf{s}^{(0)} (\mathbf{s}^{(0)})^T \mathbf{V}^{(1)} \mathbf{V}^{(2)} \dots \mathbf{V}^{(t)} \\ &\quad + (\mathbf{V}^{(t)})^T (\mathbf{V}^{(t-1)})^T \dots (\mathbf{V}^{(2)})^T \rho^{(1)} \mathbf{s}^{(1)} (\mathbf{s}^{(1)})^T \mathbf{V}^{(2)} \dots \mathbf{V}^{(t)} \\ &\quad + \dots \\ &\quad + (\mathbf{V}^{(t)})^T \rho^{(t-1)} \mathbf{s}^{(t-1)} (\mathbf{s}^{(t-1)})^T \mathbf{V}^{(t)} \\ &\quad + \rho^{(t)} \mathbf{s}^{(t)} (\mathbf{s}^{(t)})^T \end{aligned}$$

计算将

$$\mathbf{D}^{(t+1)}$$

需要用到

$$\{\mathbf{s}^{(k)}, \mathbf{y}^{(k)}\}_{k=0}^t$$

如果只能存储m组

$$(\mathbf{s}^{(k)}, \mathbf{y}^{(k)})$$

$$\mathbf{D}^{(1)}, \dots, \mathbf{D}^{(m)}$$

要丢弃一部分

$$(\mathbf{s}^{(k)}, \mathbf{y}^{(k)})$$

的话，丢弃较早生成的那些

$$(\mathbf{s}^{(k)}, \mathbf{y}^{(k)})$$

则计算

$$\mathbf{D}^{(m+1)}$$

只存储了

$$\{\mathbf{s}^{(k)}, \mathbf{y}^{(k)}\}_{k=1}^m$$

丢弃了

$$\{\mathbf{s}^{(k)}, \mathbf{y}^{(k)}\}_{k=0}^1$$

由于丢弃了部分信息，只能近似计算

$$\mathbf{D}^{(m+1)}$$

当 $t > m + 1$ 时，构造近似公式：

$$\begin{aligned} \mathbf{D}^{(t+1)} &= (\mathbf{V}^{(t)})^T (\mathbf{V}^{(t-1)})^T \dots (\mathbf{V}^{(t-m+1)})^T \mathbf{D}^{(0)} \mathbf{V}^{(t-m+1)} \dots \mathbf{V}^{(t)} \\ &\quad + (\mathbf{V}^{(t)})^T (\mathbf{V}^{(t-1)})^T \dots (\mathbf{V}^{(t-m+2)})^T \rho^{(0)} \mathbf{s}^{(0)} (\mathbf{s}^{(0)})^T \mathbf{V}^{(1)} \mathbf{V}^{(1)} \dots \mathbf{V}^{(t)} \\ &\quad + \dots \\ &\quad + (\mathbf{V}^{(t)})^T \rho^{(t-1)} \mathbf{s}^{(t-1)} (\mathbf{s}^{(t-1)})^T \mathbf{V}^{(t)} \end{aligned}$$



知乎 @大咸鱼

$$\mathbf{D}^{(t)}$$

是为了得到搜索方向

$$\mathbf{d}^{(t)} = \mathbf{D}^{(t)} \mathbf{g}^{(t)}$$

利用上面的公式，设计快速计算

$$\mathbf{D}^{(t)} \mathbf{g}^{(t)}$$

的方法

1、初始化：

$$\delta = \begin{cases} 0 & \text{if } t \leq m \\ t - m & \text{otherwise} \end{cases}, L = \begin{cases} t & \text{if } t \leq m \\ m & \text{otherwise} \end{cases}$$

2、向后循环：

$$\begin{aligned} & \text{for } i = L - 1, L - 2, \dots, 1, 0 \\ & \{ \\ & \quad j = i + \delta; \\ & \quad \alpha_i = \rho_j \mathbf{s}_j^T \mathbf{q}_{i+1}; \quad // \text{前向循环汇中还要用到} \\ & \quad \mathbf{q}_i = \mathbf{q}_{i+1} - \alpha_i \mathbf{y}_j; \\ & \} \end{aligned}$$

知乎 @大咸鱼

3、向前循环：

$$\begin{aligned} & \mathbf{r}_0 = \mathbf{D}^{(0)} \mathbf{q}_0 \\ & \text{for } i = 0, \dots, L - 1 \\ & \{ \\ & \quad j = i + \delta; \\ & \quad \beta_j = \rho_j \mathbf{y}_j^T \mathbf{r}_i; \\ & \quad \mathbf{r}_{i+1} = \mathbf{r}_i + (\alpha_i - \beta_j) \mathbf{y}_j; \\ & \} \end{aligned}$$

知乎 @大咸鱼

4、

发布于 2022-05-27 12:18

牛顿法 计算机视觉 人工智能算法

写下你的评论...



还没有评论，发表第一个评论吧

推荐阅读



理解牛顿法

SIGAI

牛顿法和拟牛顿法

牛顿法 (Newton method) 和拟牛顿法 (quasi Newton method) 是求解无约束最优化问题的常用方法，有收敛速度快的优点。牛顿法是迭代算法，每一步都需求解目标函数的海塞矩阵 (Hessian...

Pikac... 发表于机器学习...

牛顿法和拟牛顿法

导言牛顿法和拟牛顿法也是求解无约束最优化问题的常用方法【另一常用方法为：梯度下降法】，有收敛速度快的优点。牛顿法是迭代算法，每一步需要求解目标函数的 Hessian 矩阵的逆矩阵，计算...

多鱼

牛顿法进阶

在之前的文章我们介绍过，种，目标函数是每次迭代牛表示为 $\mathbf{p}_k^N = -\mathbf{a}$

王金戈